
算法 1 训练主循环（每 epoch）

输入: 训练集 $\mathcal{D}_{\text{train}}$; 验证集 $\{\mathcal{D}_{\text{val}}^k\}$; 模型 $F = g_\phi \circ f_\theta$; 优化器 $\mathcal{O}$; Mixup 配置 $\mathcal{M}$; 采样器配置 $\mathcal{S}$; E 轮; 评估间隔 T (步数)

输出: 按主指标 (AUC) 选出的最佳模型检查点

```
1: for epoch = 1 to  $E$  do
2:   for each batch  $\mathcal{B} = \{(\mathbf{x}_i, y_i)\} \subset \mathcal{D}_{\text{train}}$  do
3:     // 步骤 1: 在线 Mixup 增强 (仅训练时执行)
4:     if  $\mathcal{M}.\text{use\_mixup}$  then
5:       if  $\mathcal{S}.\text{v2}$  (BalancePairSampler) then
6:          $\{(\tilde{\mathbf{x}}_k, \tilde{y}_k, 0)\} \leftarrow \text{RFPaIRLAPPyramidMixup}(\mathcal{B})$  ▷ 算法 7
7:       else
8:          $\{(\tilde{\mathbf{x}}_i, \tilde{y}_i, y_i^{\text{hard}})\} \leftarrow \text{LAPPyramidMixup}(\mathcal{B})$  ▷ 算法 6
9:       end if
10:    end if
11:    // 步骤 2: 前向传播
12:     $\mathbf{Z} \leftarrow f_\theta(\tilde{\mathbf{X}})$ ;  $\mathbf{P} \leftarrow g_\phi(\mathbf{Z})$ 
13:    // 步骤 3: 损失计算 (算法 3)
14:     $\mathbf{L} \leftarrow \text{LossComputation}(\mathbf{P}, \tilde{\mathbf{y}})$ 
15:    // 步骤 4: 标准反向传播
16:     $\mathcal{O}.\text{zero\_grad}()$ 
17:     $\mathbf{L}.\text{overall.backward}()$ 
18:     $\mathcal{O}.\text{step}()$ 
19:    // 步骤 5: 定期评估
20:    if  $\text{global\_step} \bmod T = 0$  then
21:      for each  $\mathcal{D}_{\text{val}}^k$  do
22:         $\text{metrics}_k \leftarrow \text{Evaluate}(F, \mathcal{D}_{\text{val}}^k)$ 
23:        若 AUC 提升则更新最佳检查点
24:      end for
25:    end if
26:     $\text{global\_step} \leftarrow \text{global\_step} + 1$ 
27:  end for
28: end for
29: return 最佳检查点
```

算法 2 模型架构: CLIP ViT-L/14 + LoRA 适配

输入: 预训练 CLIP ViT-L/14 Φ ; 目标模块 $\mathcal{T} = \{\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o\}$; LoRA 秩 $r_{\text{attn}} = 4$, $r_{\text{head}} = 2$;
 LoRA 缩放因子 $\alpha_{\text{attn}} = 16$, $\alpha_{\text{head}} = 8$; 标志 `full_train_head` (True = 全量训练分类头, False = LoRA 头)

输出: 可训练检测器 $F(\cdot) = g_\phi \circ f_\theta(\cdot)$

```

1: // 步骤 1: 冻结骨干网络全部参数
2: for  $\mathbf{W} \in \Phi.\text{parameters}()$  do
3:    $\mathbf{W}.\text{requires\_grad} \leftarrow \text{False}$ 
4: end for
5: // 步骤 2: 向注意力投影矩阵注入 LoRA
6: for each module  $\mathbf{W} \in \Phi.\text{vision\_model.modules}()$  do
7:   if  $\mathbf{W}$  是 Linear 层  $\wedge \text{name}(\mathbf{W}) \in \mathcal{T}$  then
8:      $\mathbf{A} \sim \mathcal{N}(0, 0.02^2) \in \mathbb{R}^{d_{\text{in}} \times r_{\text{attn}}}$ 
9:      $\mathbf{B} \leftarrow \mathbf{0} \in \mathbb{R}^{r_{\text{attn}} \times d_{\text{out}}}$ 
10:    // 将预训练权重拷贝至新 LoRA 层, 再替换
11:     $\widetilde{\mathbf{W}}.\text{weight} \leftarrow \mathbf{W}.\text{weight}$ ;  $\widetilde{\mathbf{W}}.\text{bias} \leftarrow \mathbf{W}.\text{bias}$ 
12:    替换  $\mathbf{W}$  为  $\widetilde{\mathbf{W}}(\mathbf{x}) = \mathbf{W}\mathbf{x} + \frac{\alpha_{\text{attn}}}{r_{\text{attn}}} \cdot (\mathbf{x}\mathbf{A})\mathbf{B}$ 
13:     $\mathbf{W}.\text{requires\_grad} \leftarrow \text{False}$ ;  $\mathbf{A}, \mathbf{B}.\text{requires\_grad} \leftarrow \text{True}$ 
14:   end if
15: end for
16: // 步骤 3: 构造分类头
17:  $\mathbf{W}_h \sim \text{Kaiming\_uniform} \in \mathbb{R}^{2 \times 1024}$ 
18:  $\mathbf{b}_h \sim \mathcal{U}(-\text{bound}, \text{bound}) \in \mathbb{R}^2$ 
19: if full_train_head then
20:    $\mathbf{W}_h.\text{requires\_grad} \leftarrow \text{True}$ ;  $\mathbf{b}_h.\text{requires\_grad} \leftarrow \text{True}$ 
21:    $g_\phi(\mathbf{z}) \leftarrow \mathbf{W}_h\mathbf{z} + \mathbf{b}_h$ 
22: else
23:    $\mathbf{W}_h.\text{requires\_grad} \leftarrow \text{False}$ ;  $\mathbf{b}_h.\text{requires\_grad} \leftarrow \text{False}$ 
24:   // LoRA 因子 (可训练):  $\mathbf{A}_h \in \mathbb{R}^{1024 \times r_{\text{head}}}$ ,  $\mathbf{B}_h \in \mathbb{R}^{r_{\text{head}} \times 2}$ 
25:    $\mathbf{A}_h \sim \mathcal{N}(0, 0.02^2)$ ;  $\mathbf{B}_h \leftarrow \mathbf{0}$ 
26:   // 分类头前向:  $g_\phi(\mathbf{z}) = \underbrace{\mathbf{W}_h\mathbf{z} + \mathbf{b}_h}_{\text{冻结基座}} + \underbrace{\frac{\alpha_{\text{head}}}{r_{\text{head}}} \cdot (\mathbf{z}\mathbf{A}_h)\mathbf{B}_h}_{\text{可训练 LoRA}} \in \mathbb{R}^2$ 
27: end if
28: // 步骤 4: 完整前向传播
29:  $f_\theta(\mathbf{x}) = \Phi_{\text{LoRA}}(\mathbf{x}).\text{pooler\_output} \in \mathbb{R}^{1024}$ 
30:  $\hat{y} = \text{softmax}(g_\phi(f_\theta(\mathbf{x})))_1$ 
31: return  $F(\cdot) = g_\phi \circ f_\theta$ 

```

▷ 全部 2050 参数可训练
 ▷ ViT 输出: 经 LoRA 注意力后的 CLS token
 ▷ 预测为假图的概率

算法 3 损失计算

输入: Logits $\mathbf{P} \in \mathbb{R}^{B \times 2}$; 软标签 $\tilde{\mathbf{y}} \in [0, 1]^B$ (Mixup 激活时提供) 或硬标签 $\mathbf{y} \in \{0, 1\}^B$

输出: 损失字典 $\{\text{overall_loss}, \text{real_loss}, \text{fake_loss}\}$

```
1: // 主损失: 软标签或硬标签交叉熵
2: if 提供了  $\tilde{\mathbf{y}}$  (Mixup 激活) then
3:    $\mathbf{L}_{\text{ce}} \leftarrow -[\tilde{\mathbf{y}} \cdot \log \text{softmax}(\mathbf{P})_1 + (1 - \tilde{\mathbf{y}}) \cdot \log \text{softmax}(\mathbf{P})_0]$ 
4:    $\mathcal{L}_{\text{overall}} \leftarrow \frac{1}{B} \sum_{i=1}^B L_{\text{ce},i}$ 
5:   // 按软标签加权分解 (用于日志与监控)
6:    $w_{\text{real}} \leftarrow \sum_i (1 - \tilde{y}_i); \quad w_{\text{fake}} \leftarrow \sum_i \tilde{y}_i$ 
7:    $\mathcal{L}_{\text{real}} \leftarrow \frac{1}{\max(w_{\text{real}}, 1)} \sum_i (1 - \tilde{y}_i) \cdot L_{\text{ce},i}$ 
8:    $\mathcal{L}_{\text{fake}} \leftarrow \frac{1}{\max(w_{\text{fake}}, 1)} \sum_i \tilde{y}_i \cdot L_{\text{ce},i}$ 
9: else
10:   $\mathbf{L}_{\text{ce}} \leftarrow \text{CrossEntropy}(\mathbf{P}, \mathbf{y})$ 
11:   $\mathcal{L}_{\text{overall}} \leftarrow \frac{1}{B} \sum_{i=1}^B L_{\text{ce},i}$ 
12:  // 按硬标签类别分解
13:   $\mathcal{L}_{\text{real}} \leftarrow \frac{1}{|\{i: y_i=0\}|} \sum_{i: y_i=0} \text{CE}(\mathbf{P}_i, y_i)$ 
14:   $\mathcal{L}_{\text{fake}} \leftarrow \frac{1}{|\{i: y_i=1\}|} \sum_{i: y_i=1} \text{CE}(\mathbf{P}_i, y_i)$ 
15: end if
16: return  $\{\text{overall} : \mathcal{L}_{\text{overall}}, \text{real\_loss} : \mathcal{L}_{\text{real}}, \text{fake\_loss} : \mathcal{L}_{\text{fake}}\}$ 
```

算法 4 BalanceBatchSampler (v1): 可控真假比例的小批次构造

输入: 数据集标签 $\mathbf{y} \in \{0, 1\}^N$ ($0 = \text{真}, 1 = \text{假}$); 批次控制参数 $b \in \mathbb{N}^+$ (批次总大小 $\approx 2b$); 真图比例 $\rho \in (0, 1)$ (每批中真图占比, 默认 0.5); 打乱标志 $s \in \{\text{True}, \text{False}\}$

输出: 小批次数列 $\{\mathcal{B}_t\}_{t=0}^{M-1}$, $|\mathcal{B}_t| = n_r + n_f$, 其中 n_r/n_f 服从 ρ

```
1:  $\mathcal{I}_0 \leftarrow \{i \mid \mathbf{y}[i] = 0\}; \quad \mathcal{I}_1 \leftarrow \{i \mid \mathbf{y}[i] = 1\}$ 
2:  $n_r \leftarrow \max(1, \lfloor 2b \cdot \rho \rfloor); \quad n_f \leftarrow 2b - n_r$ 
3:  $M \leftarrow \min(\lfloor |\mathcal{I}_0| / n_r \rfloor, \lfloor |\mathcal{I}_1| / n_f \rfloor)$ 
4: if  $M = 0$  then
5:   raise ValueError (样本数不足  $n_r + n_f$ )
6: end if
7: // 步骤 1: 各类内部独立打乱
8: if  $s$  then
9:    $\mathcal{I}_0 \leftarrow \text{Shuffle}(\mathcal{I}_0); \quad \mathcal{I}_1 \leftarrow \text{Shuffle}(\mathcal{I}_1)$ 
10: end if
11: // 步骤 2: 轮询构造批次
12:  $\mathbb{B} \leftarrow []$ 
13: for  $t = 0$  to  $M - 1$  do
14:    $\mathcal{B}_t \leftarrow []$ 
15:    $\mathcal{B}_t.\text{extend}(\mathcal{I}_0[t \cdot n_r : (t + 1) \cdot n_r])$   $\triangleright n_r$  张真图
16:    $\mathcal{B}_t.\text{extend}(\mathcal{I}_1[t \cdot n_f : (t + 1) \cdot n_f])$   $\triangleright n_f$  张假图
17:    $\mathbb{B}.\text{append}(\mathcal{B}_t)$ 
18: end for
19: // 步骤 3: 打乱批次顺序
20: if  $s$  then
21:    $\mathbb{B} \leftarrow \text{Shuffle}(\mathbb{B})$ 
22: end if
23: return  $\mathbb{B}$ 
24: 关键参数:  $\rho = 0.5$  为等量基线;  $\rho = 0.7 \sim 0.85$  为高真图比例。
25: 限制: 当前仅支持单 GPU 训练 (DDP 未适配)。
```

算法 5 BalancePairSampler (v2): 显式 (真图, 假图) 配对构造

输入: 数据集标签 $\mathbf{y} \in \{0, 1\}^N$ ($0 = \text{真}, 1 = \text{假}$); 每批配对数 $P \in \mathbb{N}^+$; 打乱标志 $s \in \{\text{True}, \text{False}\}$

输出: 交替配对批次数列 $\{\mathcal{B}_t\}_{t=0}^{M-1}$, 每个 $\mathcal{B}_t = [r_1, f_1, r_2, f_2, \dots, r_P, f_P]$ (长度 $2P$)

```
1:  $\mathcal{I}_0 \leftarrow \{i \mid \mathbf{y}[i] = 0\}; \quad \mathcal{I}_1 \leftarrow \{i \mid \mathbf{y}[i] = 1\}$ 
2:  $M \leftarrow \lfloor \min(|\mathcal{I}_0|, |\mathcal{I}_1|) / P \rfloor$ 
3: if  $M = 0$  then
4:   raise ValueError (样本数不足  $P$  对)
5: end if
6: // 步骤 1: 各类内部独立打乱
7: if  $s$  then
8:    $\mathcal{I}_0 \leftarrow \text{Shuffle}(\mathcal{I}_0); \quad \mathcal{I}_1 \leftarrow \text{Shuffle}(\mathcal{I}_1)$ 
9: end if
10: // 步骤 2: 构造交替配对批次
11:  $\mathbb{B} \leftarrow []$ 
12: for  $t = 0$  to  $M - 1$  do
13:    $\mathcal{B}_t \leftarrow []$ 
14:   for  $p = 0$  to  $P - 1$  do
15:      $\mathcal{B}_t.\text{append}(\mathcal{I}_0[t \cdot P + p])$ 
16:      $\mathcal{B}_t.\text{append}(\mathcal{I}_1[t \cdot P + p])$ 
17:   end for
18:    $\mathbb{B}.\text{append}(\mathcal{B}_t)$ 
19: end for
20: // 步骤 3: 打乱批次顺序
21: if  $s$  then
22:    $\mathbb{B} \leftarrow \text{Shuffle}(\mathbb{B})$ 
23: end if
24: return  $\mathbb{B}$ 
```

▷ 真图

▷ 假图

25: **关键特性:** 批次内每个元素都是显式 (真图, 假图) 配对。

26: 配合 RFPaIRLAPYRAMIDMIXUP (算法 7),

27: 仅产生 RF 混合输出—无 RR、FF、FR 浪费。

28: **限制:** 当前仅支持单 GPU 训练 (DDP 未适配)。

算法 6 LapPyramidMixup (拉普拉斯金字塔残差混合, 配合 v1 采样器)

输入: 批次 $\{(\mathbf{x}_i, y_i)\}_{i=1}^B$, $\mathbf{x}_i \in \mathbb{R}^{C \times H \times W}$, $y_i \in \{0, 1\}$ (0 = 真, 1 = 假); $\alpha > 0$ (Beta 形状参数, 默认 5); $\gamma \geq 1$ (不对称指数, 默认 1); $K \in \mathbb{N}^+$ (金字塔层数, 默认 3); $\omega \in \mathbb{R}^K$ (层权重, 默认 $\omega_k = (K - k) / \sum_j (K - j)$); $\varepsilon = 10^{-8}$ (数值稳定常数)

输出: 混合批次 $\{(\tilde{\mathbf{x}}_i, \tilde{y}_i, y_i^{\text{hard}})\}_{i=1}^B$, 其中 $\tilde{\mathbf{x}}_i \in \mathbb{R}^{C \times H \times W}$, $\tilde{y}_i \in [0, 1]$, $y_i^{\text{hard}} \in \{0, 1\}$

1: $\lambda \sim \text{Beta}(\alpha, \alpha)$; $q \leftarrow 1 - \lambda$ ▷ 假图残差注入强度

2: $\pi \leftarrow \text{RandPerm}(\{1, \dots, B\})$

3: // 步骤 1: 按配对类型分区 (Q1 锚定规则: 真图始终为结构锚点)

4: $\mathcal{R}\mathcal{R} \leftarrow \{i \mid y_i = 0 \wedge y_{\pi(i)} = 0\}$; $n_{rr} \leftarrow |\mathcal{R}\mathcal{R}|$

5: $\mathcal{F}\mathcal{F} \leftarrow \{i \mid y_i = 1 \wedge y_{\pi(i)} = 1\}$; $n_{ff} \leftarrow |\mathcal{F}\mathcal{F}|$

6: $\mathbf{r} \leftarrow$ 跨类对中的真图锚点位置 (FR 对通过交换合并入 RF)

7: $\mathbf{f} \leftarrow$ 对应的假图伙伴位置

8: $n_{rf} \leftarrow |\mathbf{r}|$

9: // 步骤 2: RR 一像素空间混合, 硬标签 0

10: $\tilde{\mathbf{X}}_{rr} \leftarrow \lambda \cdot \mathbf{X}[\mathcal{R}\mathcal{R}] + (1 - \lambda) \cdot \mathbf{X}[\pi(\mathcal{R}\mathcal{R})]$

11: $\tilde{\mathbf{y}}_{rr} \leftarrow \mathbf{0}^{n_{rr}}$

12: // 步骤 3: FF 一像素空间混合, 硬标签 1

13: $\tilde{\mathbf{X}}_{ff} \leftarrow \lambda \cdot \mathbf{X}[\mathcal{F}\mathcal{F}] + (1 - \lambda) \cdot \mathbf{X}[\pi(\mathcal{F}\mathcal{F})]$

14: $\tilde{\mathbf{y}}_{ff} \leftarrow \mathbf{1}^{n_{ff}}$

15: // 步骤 4: RF 一拉普拉斯金字塔残差混合

16: if $n_{rf} > 0$ then

17: $\mathbf{X}_r \leftarrow \mathbf{X}[\mathbf{r}]$; $\mathbf{X}_f \leftarrow \mathbf{X}[\mathbf{f}]$ ▷ 锚点 (真图), 伙伴 (假图)

18: for $i = 1$ to n_{rf} do ▷ 逐元素配对 ($\mathbf{r}[i], \mathbf{f}[i]$)

19: $\mathbf{x}_r \leftarrow \mathbf{X}_r[i]$; $\mathbf{x}_f \leftarrow \mathbf{X}_f[i]$

20: // (a) 构建高斯金字塔 (5 抽头二项式核 [1,4,6,4,1]/16, 可分离卷积, $\downarrow 2$)

21: $\mathbf{G}_0^r \leftarrow \mathbf{x}_r$; $\mathbf{G}_0^f \leftarrow \mathbf{x}_f$

22: for $\ell = 0$ to $K - 1$ do

23: $\mathbf{G}_{\ell+1} \leftarrow \text{PyrDown}(\mathbf{G}_\ell)$

24: end for

25: // (b) 构建拉普拉斯金字塔: $\mathbf{L}_\ell = \mathbf{G}_\ell - \text{PyrUp}(\mathbf{G}_{\ell+1})$

26: // ($\text{PyrUp} =$ 双线性上采样 $\uparrow 2$, $\text{F.interpolate(mode='bilinear')}$)

27: for $\ell = 0$ to $K - 1$ do

28: $\mathbf{L}_\ell^r \leftarrow \mathbf{G}_\ell^r - \text{PyrUp}(\mathbf{G}_{\ell+1}^r)$

29: $\mathbf{L}_\ell^f \leftarrow \mathbf{G}_\ell^f - \text{PyrUp}(\mathbf{G}_{\ell+1}^f)$

30: end for

31: // (c) 逐层混合拉普拉斯残差

32: for $\ell = 0$ to $K - 1$ do

33: $\mathbf{L}_\ell^{\text{mix}} \leftarrow (1 - q) \cdot \mathbf{L}_\ell^r + q \cdot \mathbf{L}_\ell^f$

34: $E_\ell^r \leftarrow \|\mathbf{L}_\ell^r\|_F^2$; $E_\ell^f \leftarrow \|\mathbf{L}_\ell^f\|_F^2$

35: end for

36: // (d) 由残差能量占比计算 Fake 证据度

37: $\text{num} \leftarrow q^2 \sum_{\ell=0}^{K-1} \omega_\ell \cdot E_\ell^f$

38: $\text{den} \leftarrow \sum_{\ell=0}^{K-1} \omega_\ell [(1 - q)^2 \cdot E_\ell^r + q^2 \cdot E_\ell^f] + \varepsilon$

39: $e_f \leftarrow \text{num} / \text{den}$

40: // (e) 重建: 真实粗结构 + 混合残差

41: $\tilde{\mathbf{x}} \leftarrow \mathbf{G}_K^r$ ▷ 真图锚点的最粗层高斯分量

42: for $\ell = K - 1$ downto 0 do

43: $\tilde{\mathbf{x}} \leftarrow \text{PyrUp}(\tilde{\mathbf{x}}) + \mathbf{L}_\ell^{\text{mix}}$

44: end for

45: $\tilde{\mathbf{x}} \leftarrow \text{clamp}(\tilde{\mathbf{x}}, \min(\mathbf{x}_r), \max(\mathbf{x}_r))$

46: // (f) 能量锚定软标签 (Aggressively Fake)

47: $\tilde{y} \leftarrow 1 - (1 - e_f)^\gamma$

48: end for

49: end if

50: // 步骤 5: 组装最终批次

51: $\tilde{\mathbf{X}} \leftarrow \text{Concat}(\tilde{\mathbf{X}}_{rr}, \tilde{\mathbf{X}}_{ff}, \tilde{\mathbf{X}}_{rf})$

52: $\tilde{\mathbf{y}} \leftarrow \text{Concat}(\tilde{\mathbf{y}}_{rr}, \tilde{\mathbf{y}}_{ff}, \tilde{\mathbf{y}}_{rf})$

53: $\mathbf{y}^{\text{hard}} \leftarrow \text{Concat}(\mathbf{0}^{n_{rr}}, \mathbf{1}^{n_{ff}}, \mathbf{0}^{n_{rf}})$

54: return $\{(\tilde{\mathbf{x}}_i, \tilde{y}_i, y_i^{\text{hard}})\}$

算法 7 RFPairLapPyramidMixup (v2 采样器, 仅 RF 配对)

输入: 来自 BALANCEPAIRSAMPLER 的交替配对批次 $\{(\mathbf{x}_i, y_i)\}_{i=1}^{2N}$, 含配对 $(r_k, f_k)_{k=1}^N$; $\alpha > 0$; $\gamma \geq 1$; $K \in \mathbb{N}^+$; ω ; ε (同算法 6)

输出: 混合批次 $\{(\tilde{\mathbf{x}}_k, \tilde{y}_k, y_k^{\text{hard}})\}_{k=1}^N$ ($2N$ 输入 $\rightarrow N$ 输出)

```

1:  $\lambda \sim \text{Beta}(\alpha, \alpha)$ ;  $q \leftarrow 1 - \lambda$ 
2:  $\mathbf{X}_r \leftarrow \mathbf{X}[0 :: 2]$ 
3:  $\mathbf{X}_f \leftarrow \mathbf{X}[1 :: 2]$ 
4: // 无需配对类型分类—每对都是 (真图, 假图)
5: // 高斯金字塔 (批次并行)
6:  $\mathbf{G}_0^r \leftarrow \mathbf{X}_r$ ;  $\mathbf{G}_0^f \leftarrow \mathbf{X}_f$ 
7: for  $\ell = 0$  to  $K - 1$  do
8:    $\mathbf{G}_{\ell+1}^r \leftarrow \text{PyrDown}(\mathbf{G}_\ell^r)$ 
9:    $\mathbf{G}_{\ell+1}^f \leftarrow \text{PyrDown}(\mathbf{G}_\ell^f)$ 
10: end for
11: // 拉普拉斯金字塔
12: for  $\ell = 0$  to  $K - 1$  do
13:    $\mathbf{L}_\ell^r \leftarrow \mathbf{G}_\ell^r - \text{PyrUp}(\mathbf{G}_{\ell+1}^r)$ 
14:    $\mathbf{L}_\ell^f \leftarrow \mathbf{G}_\ell^f - \text{PyrUp}(\mathbf{G}_{\ell+1}^f)$ 
15: end for
16: // 逐层混合拉普拉斯残差
17: for  $\ell = 0$  to  $K - 1$  do
18:    $\mathbf{L}_\ell^{\text{mix}} \leftarrow (1 - q) \cdot \mathbf{L}_\ell^r + q \cdot \mathbf{L}_\ell^f$ 
19:    $E_\ell^r \leftarrow \text{逐样本 } \|\mathbf{L}_\ell^r\|_F^2 \in \mathbb{R}^N$ ;  $E_\ell^f \leftarrow \text{逐样本 } \|\mathbf{L}_\ell^f\|_F^2 \in \mathbb{R}^N$ 
20: end for
21: // Fake 证据度 (逐样本能量占比)
22:  $\text{num} \leftarrow q^2 \sum_{\ell=0}^{K-1} \omega_\ell \cdot E_\ell^f$ 
23:  $\text{den} \leftarrow \sum_{\ell=0}^{K-1} \omega_\ell [(1 - q)^2 \cdot E_\ell^r + q^2 \cdot E_\ell^f] + \varepsilon$ 
24:  $\mathbf{e}_f \leftarrow \text{num} / \text{den} \in \mathbb{R}^N$ 
25: // 重建: 真实粗结构 + 混合残差
26:  $\tilde{\mathbf{X}} \leftarrow \mathbf{G}_K^r$ 
27: for  $\ell = K - 1$  downto 0 do
28:    $\tilde{\mathbf{X}} \leftarrow \text{PyrUp}(\tilde{\mathbf{X}}) + \mathbf{L}_\ell^{\text{mix}}$ 
29: end for
30:  $\tilde{\mathbf{X}} \leftarrow \text{clamp}(\tilde{\mathbf{X}}, \min(\mathbf{X}_r), \max(\mathbf{X}_r))$ 
31: // 软标签 (全部以真图为锚点)
32:  $\tilde{y} \leftarrow 1 - (1 - \mathbf{e}_f)^\gamma \in [0, 1]^N$ 
33:  $y^{\text{hard}} \leftarrow \mathbf{0}^N$ 
34: return  $\{(\tilde{\mathbf{x}}_k, \tilde{y}_k, 0)\}_{k=1}^N$ 
35: 与算法 6 的关键区别: 无 RR/FF/FR 配对—每个输出均为 RF 混合图像。
36: 批次大小从  $2N$  (加载) 减半至  $N$  (混合后)。
```

▷ 真图锚点 $[N, C, H, W]$
 ▷ 假图伙伴 $[N, C, H, W]$

▷ 从真图的最粗高斯层开始

▷ 逐样本裁剪

▷ 所有锚点均为真图